Les algorithmes de l'apprentissage automatique

Rajae El Ouazzani

Chapitre : Les algorithmes de l'apprentissage automatique

Algorithme 1: KNN

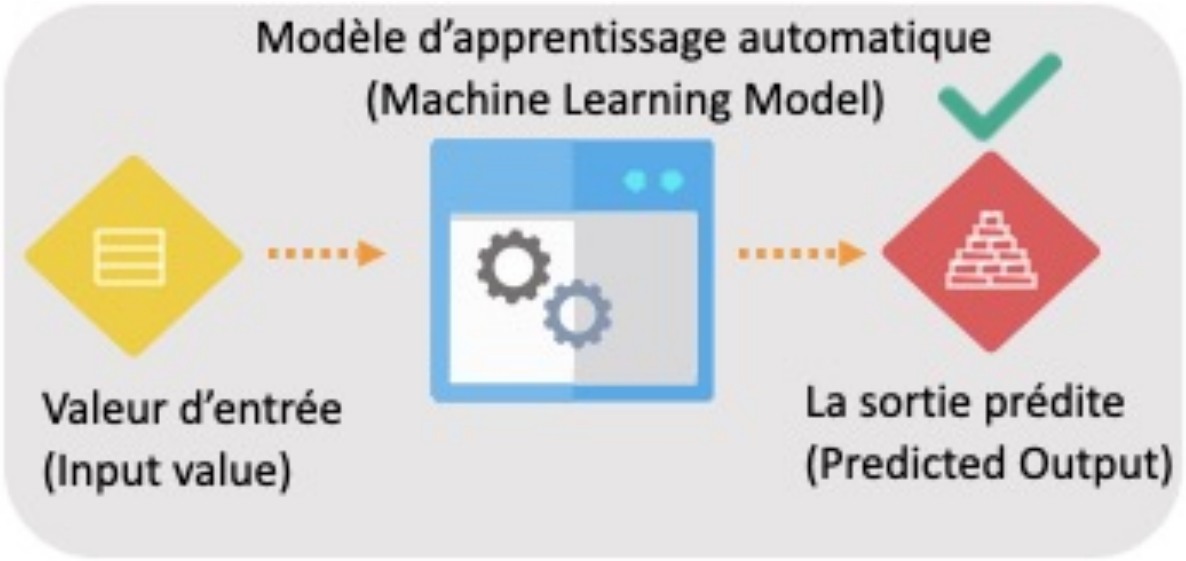
Plan

- Pourquoi avons-nous besoin de KNN ?
- Qu'est-ce que KNN ?
- Comment choisissons-nous le facteur « K » ?
- Quand utilisons-nous KNN ?
- Comment fonctionne l'algorithme KNN ?
- Evaluation des résultats de classification
- Cas d'utilisation : prédire si une personne sera diabétique ou non

Pourquoi avons-nous besoin de KNN ?

Pourquoi avons-nous besoin de KNN ?

- Nous savons tous que les modèles d'apprentissage automatique font des prédictions en apprenant des données passées disponibles.




Est ce que c’est un chien ?
Non ce n’est pas un chien. Tu peux différencier un chat et un chien en fonction de leurs caractéristiques

Pourquoi avons-nous besoin de KNN ? (Suite)

- Caractéristiques des chats et chiens:

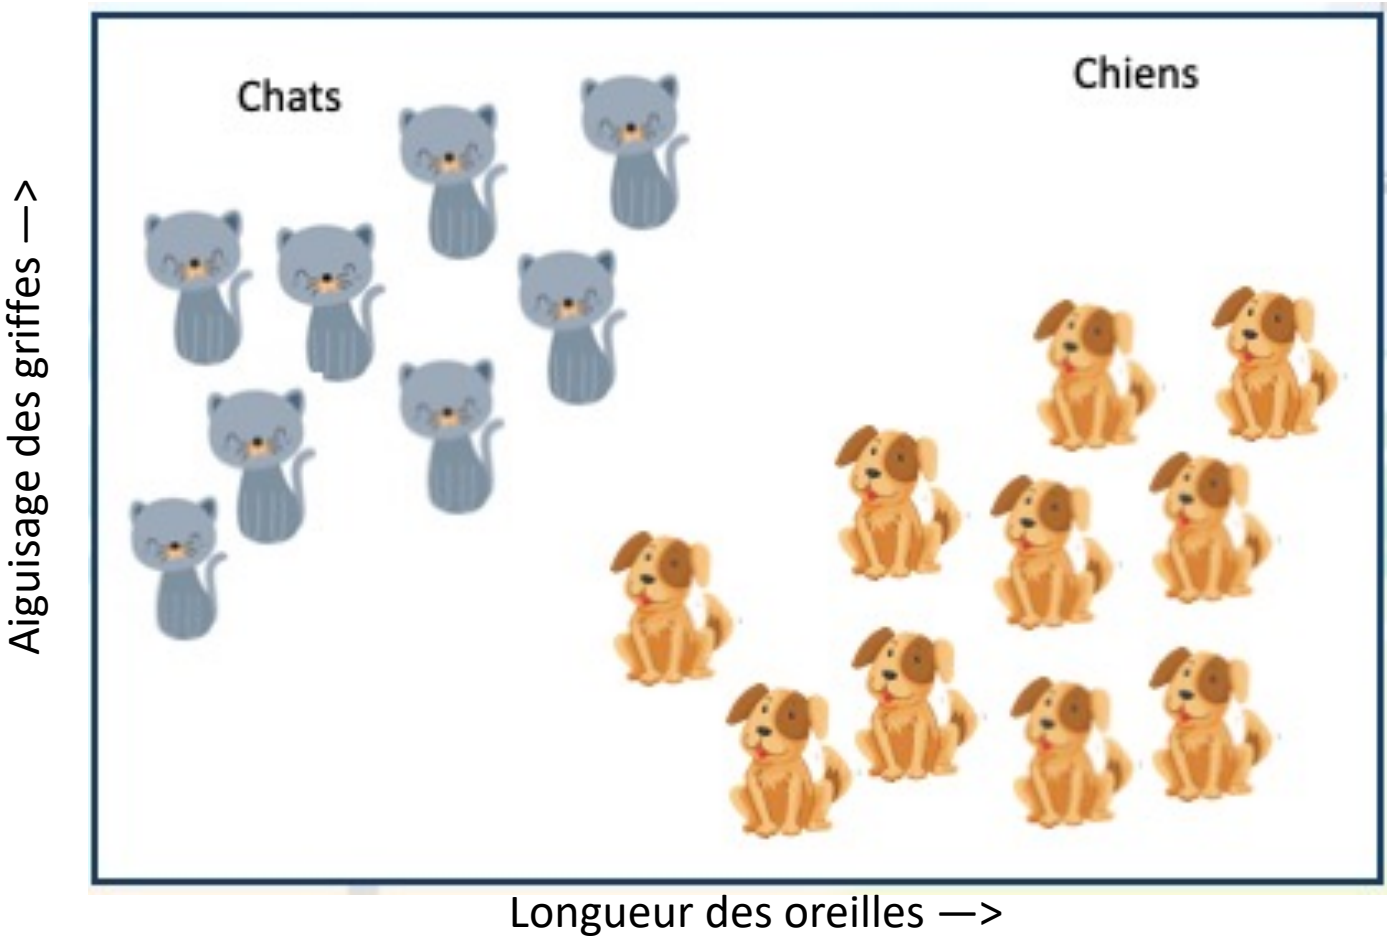
Chats	Chiens
	
Griffes acérées, utilise pour grimper	Griffes émoussées
Plus petite longueur d'oreilles	Plus grande longueur d'oreilles
Miaulements et ronronnements	Aboiements
N'aime pas jouer	Aime courir

Acéré: Dur, tranchant et pointu

Emoussé: Lame, épée

Pourquoi avons-nous besoin de KNN ? (Suite)

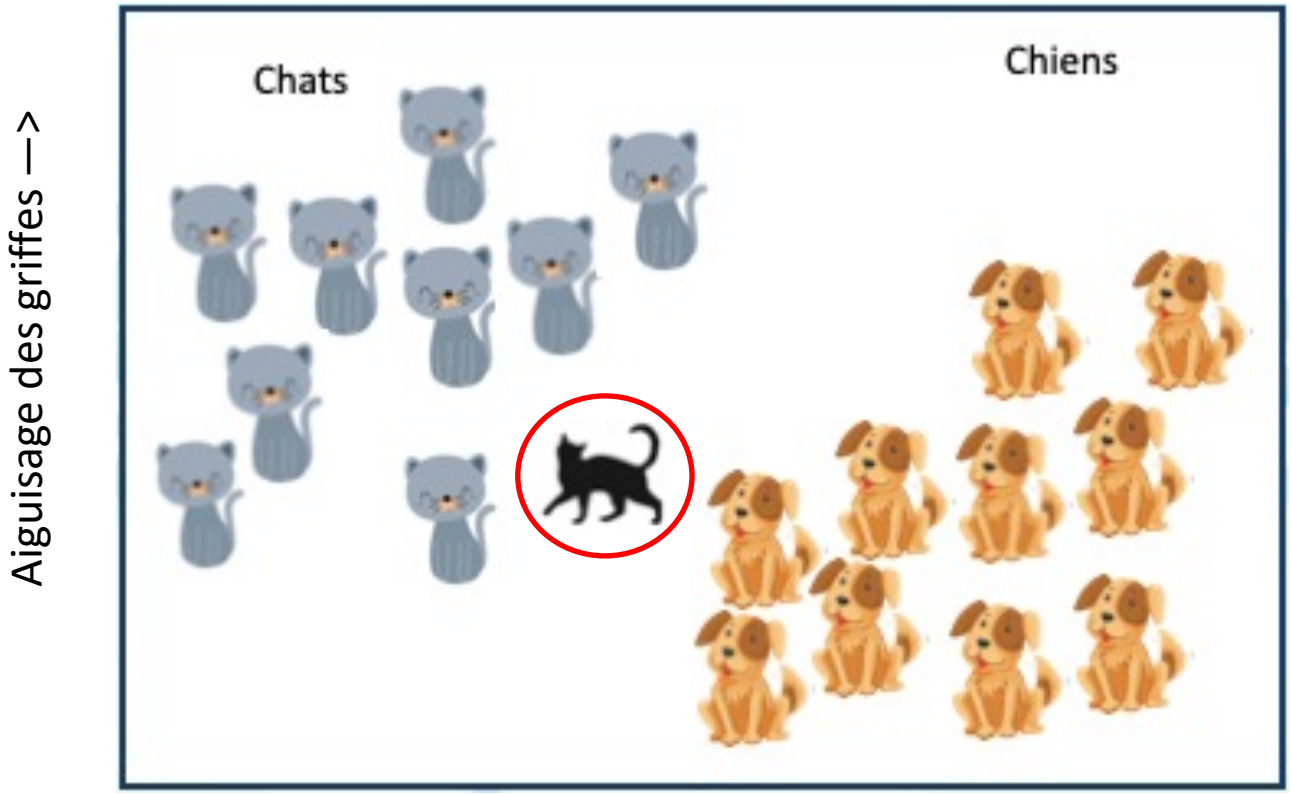
- Ce qu'on va faire: essayer d'utiliser la longueur des oreilles et l'aiguisage des griffes pour différencier les chats des chiens:



Pourquoi avons-nous besoin de KNN ? (Suite)

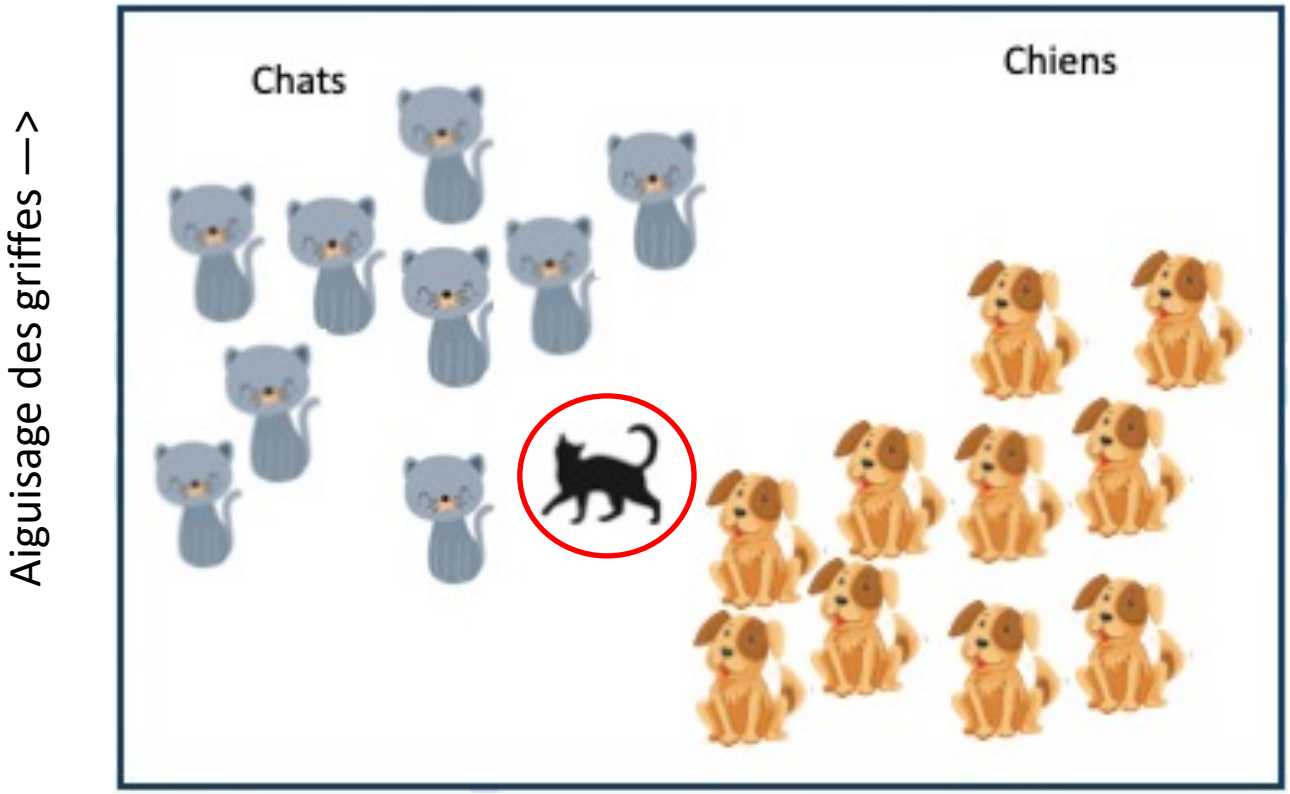
- Prendre un animal inconnu: Est ce que c'est un chat ou un chien ?

  → Comparer les caractéristiques



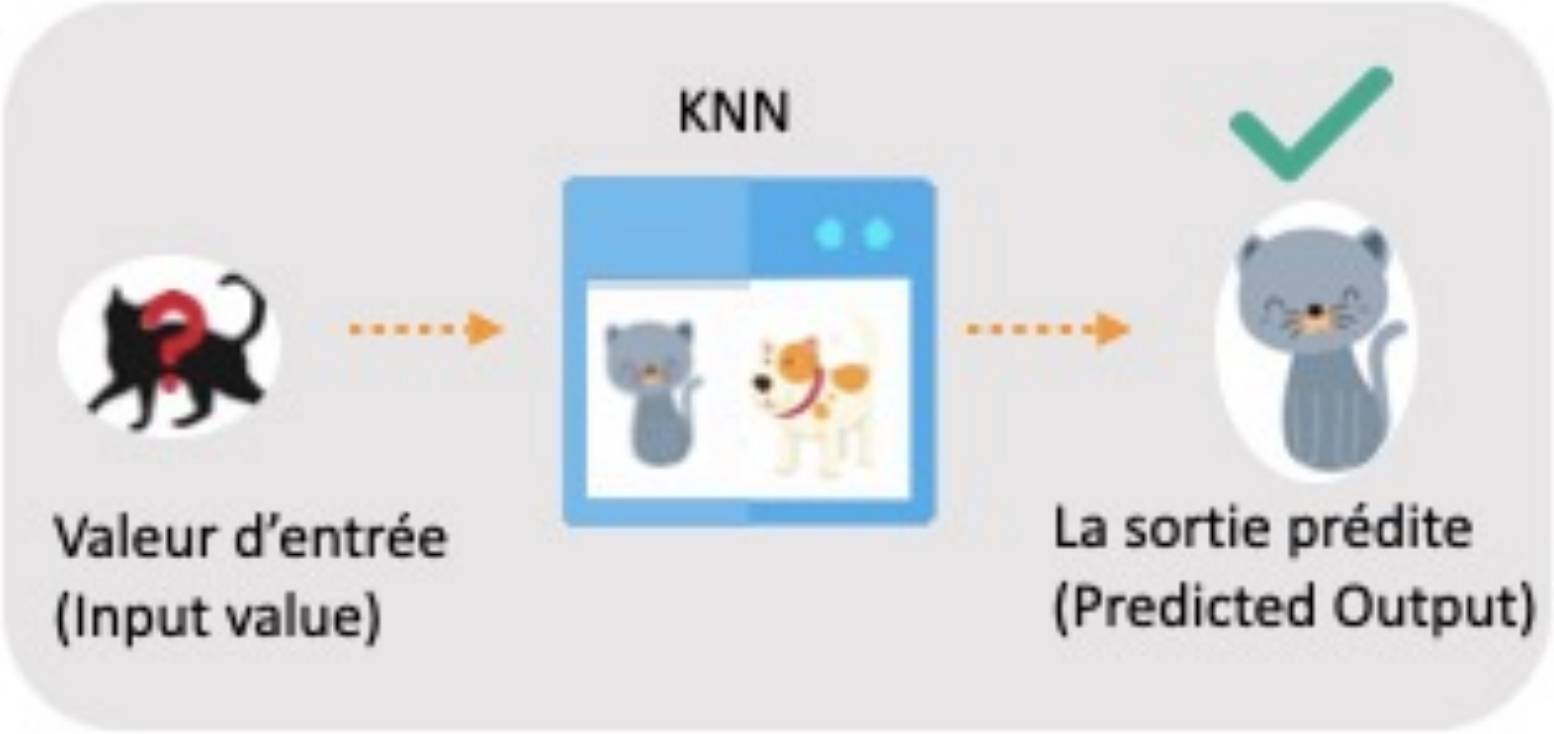
Pourquoi avons-nous besoin de KNN ? (Suite)

- Remarque: les caractéristiques de l'animal ressemblent plus à celles des chats, ce doit être un chat !



Pourquoi avons-nous besoin de KNN ? (Suite)

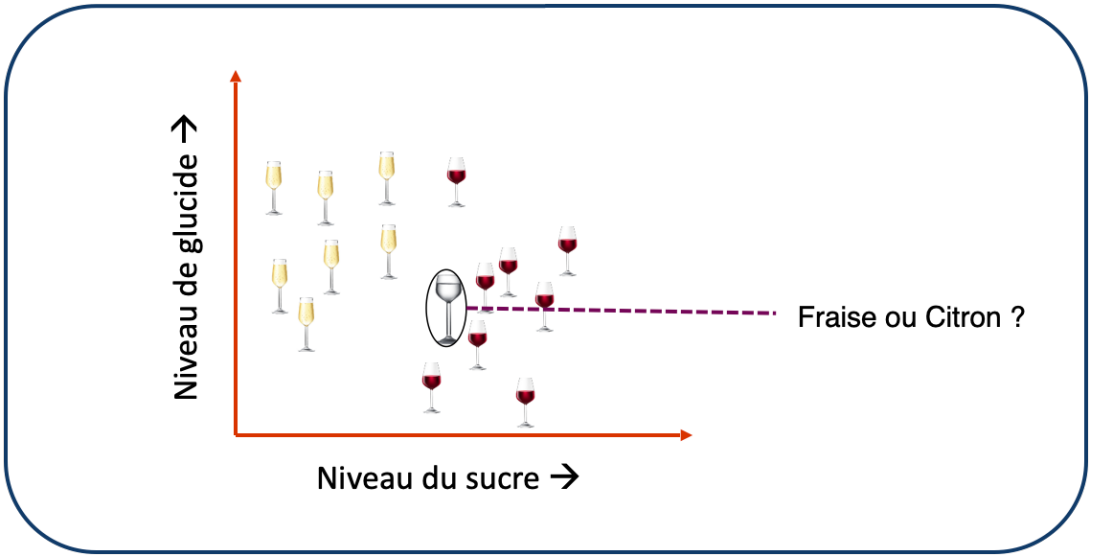
- **Récapitulation:**
- Le KNN se base sur la similarité des descripteurs/ caractéristiques (features) pour classifier les chiens et les chats !



Qu'est-ce que KNN ?

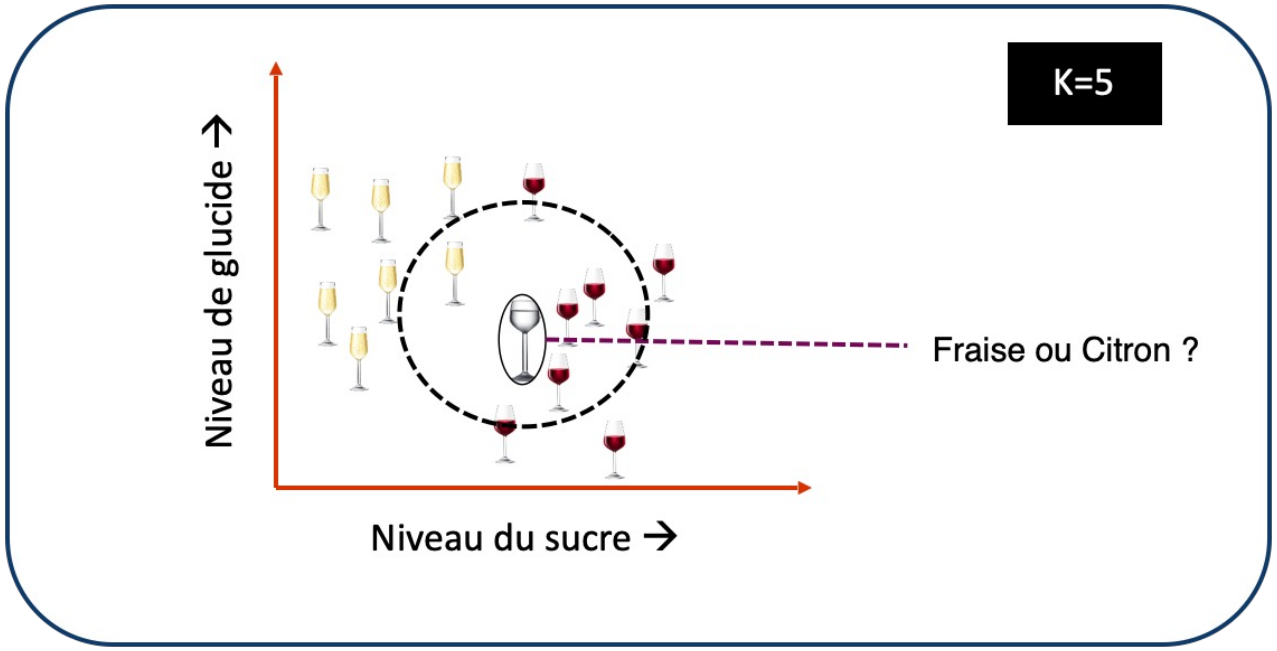
Qu'est-ce que KNN ?

- Le KNN - K Nearest Neighbors (K-plus proches voisins), est l'un des algorithmes d'**apprentissage automatique supervisé** les plus simples.
- Il est principalement utilisé pour la classification. Il classifie un point de données en fonction de la façon dont ses voisins sont classifiés.
- Le KNN stocke tous les cas disponibles (base d'apprentissage) et classifie les nouveaux cas en fonction de mesures de similarité.
- NB:
  - Fraise (sucre =5.3 et glucide = 5.3)
  - Citron (sucre =2.5 et glucide = 9.32)



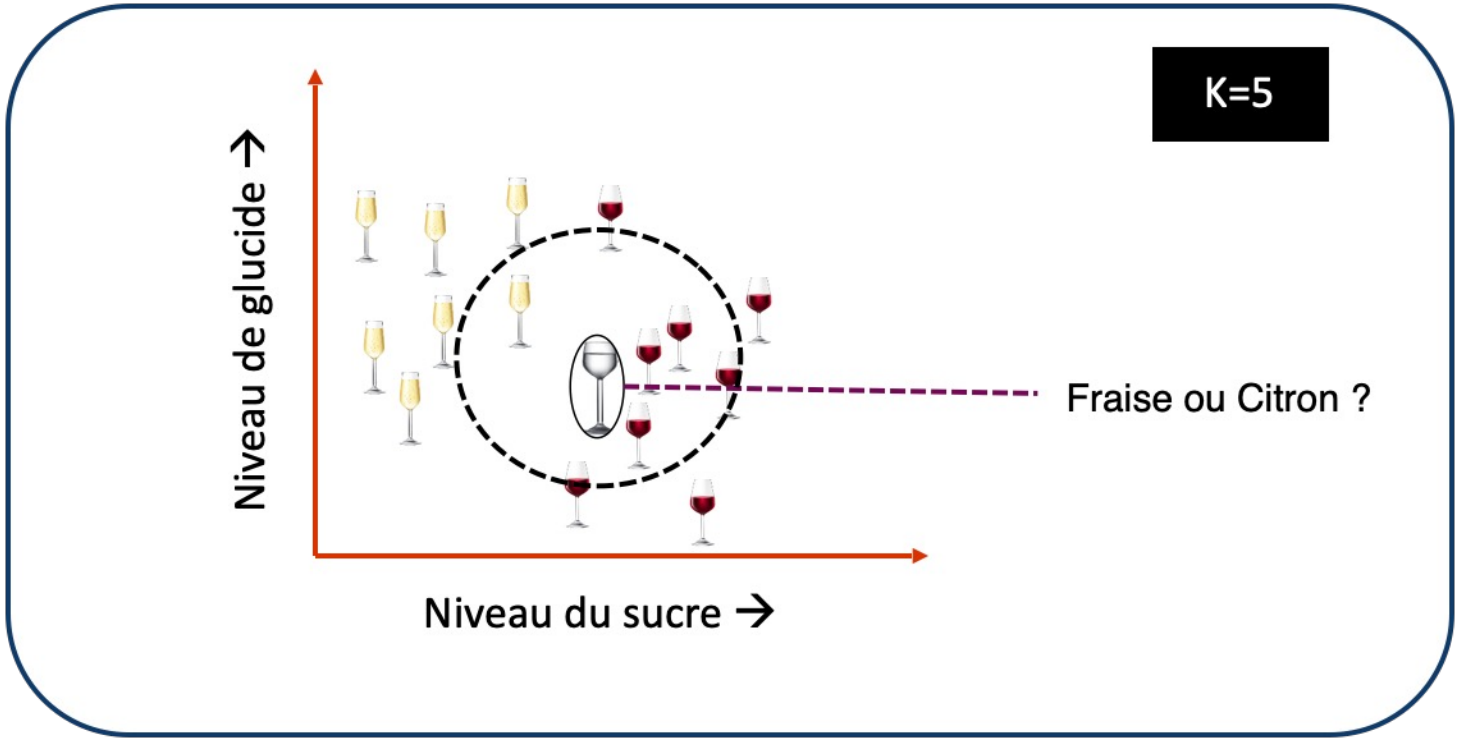
Qu'est-ce que KNN ? (Suite)

- **Que veut dire K?**
- K dans KNN est un paramètre qui fait référence au nombre de voisins les plus proches à inclure dans le processus de vote à la majorité.
- Pour K=5, un point de données est classifié par les votes majoritaires de ses 5 plus proches voisins.



Qu'est-ce que KNN ? (Suite)

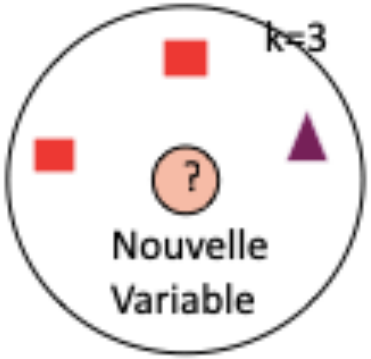
- Dans notre exemple, le point inconnu serait classifié en Fraise, puisque 4 voisins sur 5 sont roses.



Comment choisissons-nous le facteur K ?

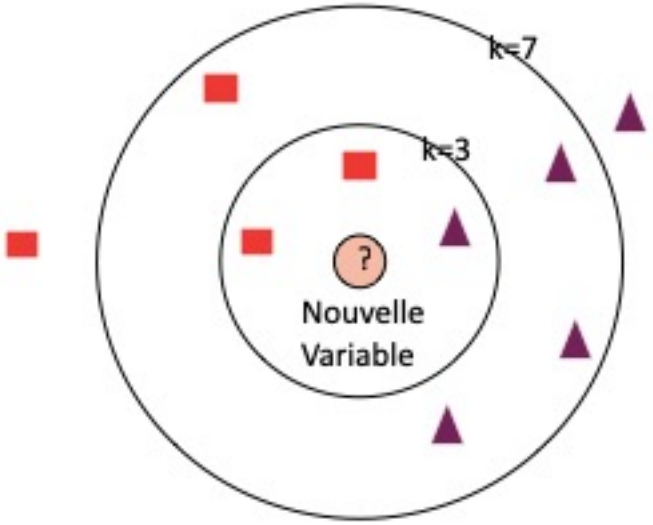
Comment choisissons-nous le facteur K ?

- L'algorithme KNN est basé sur la similarité des caractéristiques : le choix de **la bonne valeur de K** est un processus appelé **réglage des paramètres (parameters/hyperparameters tuning)** et il est important pour une meilleure précision.



Donc à k=3, on peut classifier '?' comme ■

Comment choisissons-nous le facteur K ? (Suite)



Donc à k=7, on peut classifier '?' comme ▲

- La classe des points de données inconnus était ■ à k=3 mais a changé à k=7, alors **quelle valeur de k devrions-nous choisir ?**

Comment choisissons-nous le facteur K ? (Suite)

- Pour choisir une valeur de K, on prend :
  - **Sqrt(n)**, où n est le nombre total de points de données.
  - La **valeur impaire de K** est sélectionnée pour éviter toute confusion entre deux classes de données.

- Une valeur plus élevée de K a moins de chance d'erreur.

Quand utilisons-nous KNN ?

Quand utilisons-nous KNN ?

- On utilise le KNN dans les cas suivants:
  - Les données sont étiquetées.



Chien

  - Les données sont sans bruit.

Poids (x)	Taille (y)	Classe
51	167	Poids insuffisant
62	182	un-quarante
69	176	23
64	173	Bonjour
65	172	Normal

Bruit

  - La base de données est petite.

Comment fonctionne l'algorithme KNN ?

Comment fonctionne l'algorithme KNN ?

- Considérons un ensemble de données (data set) ayant deux variables; le poids (kg) et la taille (cm) et chaque ensemble est classifié comme normal ou insuffisant.

Poids (x)	Taille (y)	Classe
51	167	Insuffisant
62	182	Normal
69	176	Normal
64	173	Normal
65	172	Normal
56	174	Insuffisant
58	169	Normal
57	173	Normal
55	170	Normal

Comment fonctionne l'algorithme KNN ? (Suite)

- Sur la base de données disponibles, comment devrons nous classer l'ensemble ci-dessous à l'aide de KNN, normal ou insuffisant?

57 kg	**170 cm**	**?**

- NB: Nous allons supposer que nous ne sachions pas comment calculer l'IMC (Indice de Masse Corporelle)!

Comment fonctionne l'algorithme KNN ? (Suite)

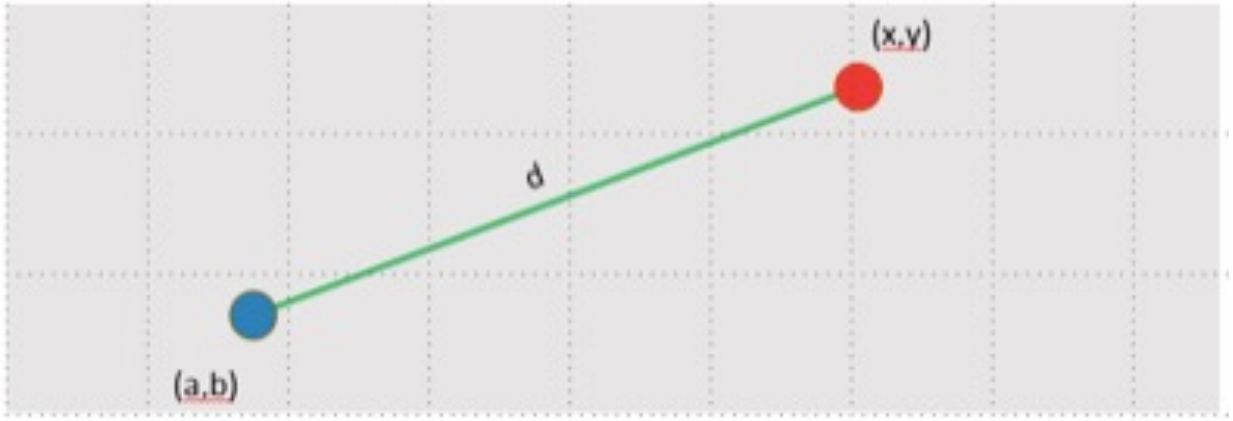
- Selon l'OMS, IMC = M/T^2 avec M la masse corporelle (en kilogrammes) et T la taille (en mètres).

Interprétation de l'IMC	
IMC (kg m^{-2})	**Interprétation**
moins de 16,5	dénutrition
16,5 à 18,5-	maigreur
18,5 à 25-	poids normal
25 à 30-	surpoids
30 à 35-	obésité modérée
35 à 40-	obésité sévère
40 et plus	obésité morbide ou massive

Comment fonctionne l'algorithme KNN ? (Suite)

- Pour trouver les voisins les plus proches, nous allons calculer la distance euclidienne.
- **Mais qu'est-ce que la distance euclidienne ?**
- Selon la formule de la distance euclidienne, la distance entre deux points du plan de coordonnées (x, y) et (a, b) est donnée par :

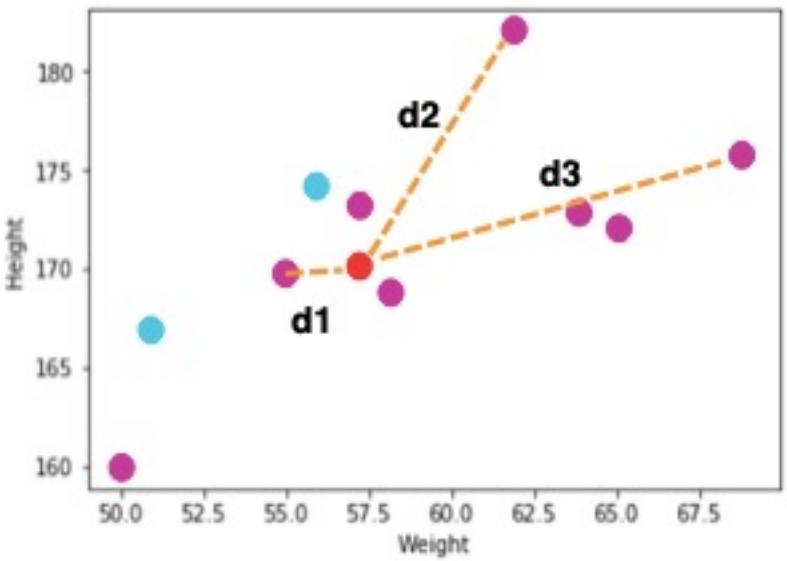
$$dist(d) = \sqrt{(x - a)^2 + (y - b)^2}$$



Comment fonctionne l'algorithme KNN ? (Suite)

- Ainsi, nous calculerons la distance euclidienne d'un point de données inconnu à partir de tous les points de l'ensemble de données.

- **Question:** Calculer les distances euclidiennes entre les entrées de la base de données et le nouveau echantillon.



: le point de données inconnu

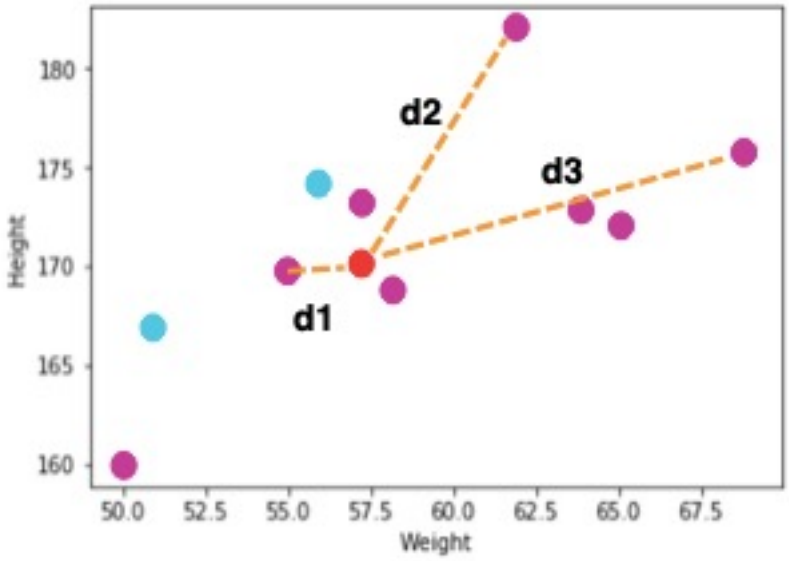
Poids (x)	Taille (y)	Classe
51	167	Insuffisant
62	182	Normal
69	176	Normal

57 kg	**170 cm**	**?**

$$dist(d) = \sqrt{(x - a)^2 + (y - b)^2}$$

Comment fonctionne l'algorithme KNN ? (Suite)

- Ainsi, nous calculerons la distance euclidienne d'un point de données inconnu à partir de tous les points de l'ensemble de données.



: le point de données inconnu

$dist(\mathbf{d1}) = \sqrt{(51-57)^2 + (167-170)^2} = \sqrt{45} \sim = 6.7$

$dist(\mathbf{d2}) = \sqrt{(62-57)^2 + (182-170)^2} = \sqrt{169} = 13$

$dist(\mathbf{d3}) = \sqrt{(69-57)^2 + (176-170)^2} = \sqrt{180} \sim = 13.4$

Poids (x)	Taille (y)	Classe
51	167	Insuffisant
62	182	Normal
69	176	Normal

57 kg	170 cm	?

$$dist(d) = \sqrt{(x - a)^2 + (y - b)^2}$$

Comment fonctionne l'algorithme KNN ? (Suite)

- Calculer les distance euclidienne réstantes:

Poids (x)	Hauteur (y)	Classe	Distance Euclidienne
51	167	Insuffisant	6.7
62	182	Normal	13
69	176	Normal	13.4
64	173	Normal	?
65	172	Normal	?
56	174	Insuffisant	?
58	169	Normal	?
57	173	Normal	?
55	170	Normal	?

Comment fonctionne l'algorithme KNN ? (Suite)

- Par conséquent, nous avons calculé la distance euclidienne du point de données inconnu à partir de tous les points de la base comme indiqué :

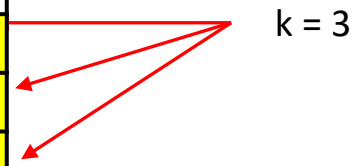
Poids (x)	Hauteur (y)	Classe	Distance Euclidienne
51	167	Insuffisant	6.7
62	182	Normal	13
69	176	Normal	13.4
64	173	Normal	7.6
65	172	Normal	8.2
56	174	Insuffisant	4.1
58	169	Normal	1.4
57	173	Normal	3
55	170	Normal	2

- Où (a, b) = (57, 170) que nous devons classifier.

Comment fonctionne l'algorithme KNN ? (Suite)

- **Déterminer la valeur de k:**
- On a n=10, et sqrt(10)=3.1. Par conséquent, nous utilisons k=3.
- Déterminons maintenant les voisins les plus proche à notre ensemble de test pour k=3.

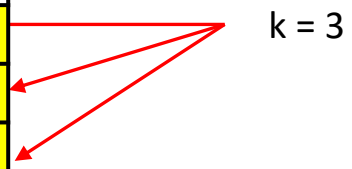
Poids (x2)	Hauteur (y2)	Classe	Distance Euclidienne
51	167	Insuffisant	6.7
62	182	Normal	13
69	176	Normal	13.4
64	173	Normal	7.6
65	172	Normal	8.2
56	174	Insuffisant	4.1
58	169	Normal	1.4
57	173	Normal	3
55	170	Normal	2



57 kg	**170 cm**	**?**

Comment fonctionne l'algorithme KNN ? (Suite)

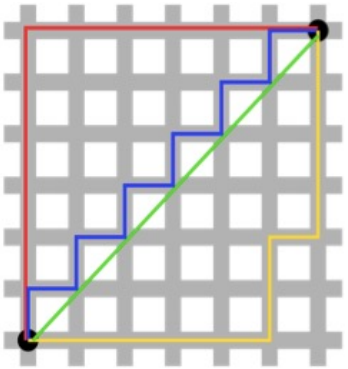
Classe	Distance Euclidienne
Insuffisant	6.7
Normal	13
Normal	13.4
Normal	7.6
Normal	8.2
Insuffisant	4.1
Normal	1.4
Normal	3
Normal	2



- Ainsi, les voisins (majoritaires) pointent vers « Normal ».
- Par conséquent, selon l'algorithme KNN, la classe de (57, 170) devrait être « Normal ».

Comment fonctionne l'algorithme KNN ? (Suite)

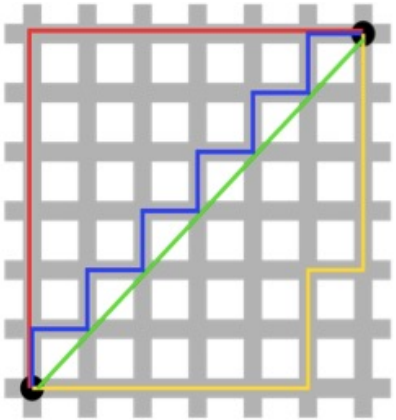
- **La distance de Manhattan**
- La distance de Manhattan est appelée aussi taxi-distance, est la distance entre deux points parcourue par un taxi lorsqu'il se déplace dans une ville où les rues sont agencées selon un réseau ou quadrillage.
- Un taxi-distance est le trajet fait par un taxi lorsqu'il se déplace d'un nœud du réseau à un autre en utilisant les déplacements horizontaux et verticaux du réseau.



Comment fonctionne l'algorithme KNN ? (Suite)

- Soit deux points point1 (x,y) et point2 (a,b).

distanceManhattan(point1,point2)=|x−a|+|y−b|



- La distance de Manhattan est réservée aux classifications hiérarchiques. En revanche, les temps de calcul sont particulièrement longs...

http://www.jybaudot.fr/Analdonnees/metriques.html

Comment fonctionne l'algorithme KNN ? (Suite)

- **La distance de Tchebychev**

- La distance de Tchebychev ou ∞-distance, est la distance entre deux points est donnée par la différence maximale entre leurs coordonnées sur une dimension.
- Soit deux points point1 (x,y) et point2 (a,b).

$$distanceTchebychev(point1,point2)=max(|x-a|,|y-b|)$$

Comment fonctionne l'algorithme KNN ? (Suite)

- Calculer les distances avec Manhattan et Tchebychev.
- Donner la/les classe(s) de l'échantillon (a, b) = (57, 170).
- DistanceManhattan(point1,point2)=|x−a|+|y−b|
- DistanceTchebychev(point1,point2)=max(|x−a|,|y−b|)

Poids (x)	Taille (y)	Classe	Distance Manhattan	Distance Tchebychev
51	167	Insuffisant		
62	182	Normal		
69	176	Normal		
64	173	Normal		
65	172	Normal		
56	174	Insuffisant		
58	169	Normal		
57	173	Normal		
55	170	Normal		

Recapitulation de KNN

- **Pour utiliser le KNN,**
  - Un entier positif k est spécifié, ainsi qu'un nouvel échantillon.
  - Nous sélectionnons les k entrées dans notre base de données qui sont les plus proches du nouvel échantillon (utiliser la distance euclidienne par exemple).
  - Nous déterminons la classe la plus courante de ces entrées.
  - C'est cette classe que nous attribuons au nouvel échantillon.

Evaluation des résultats de classification

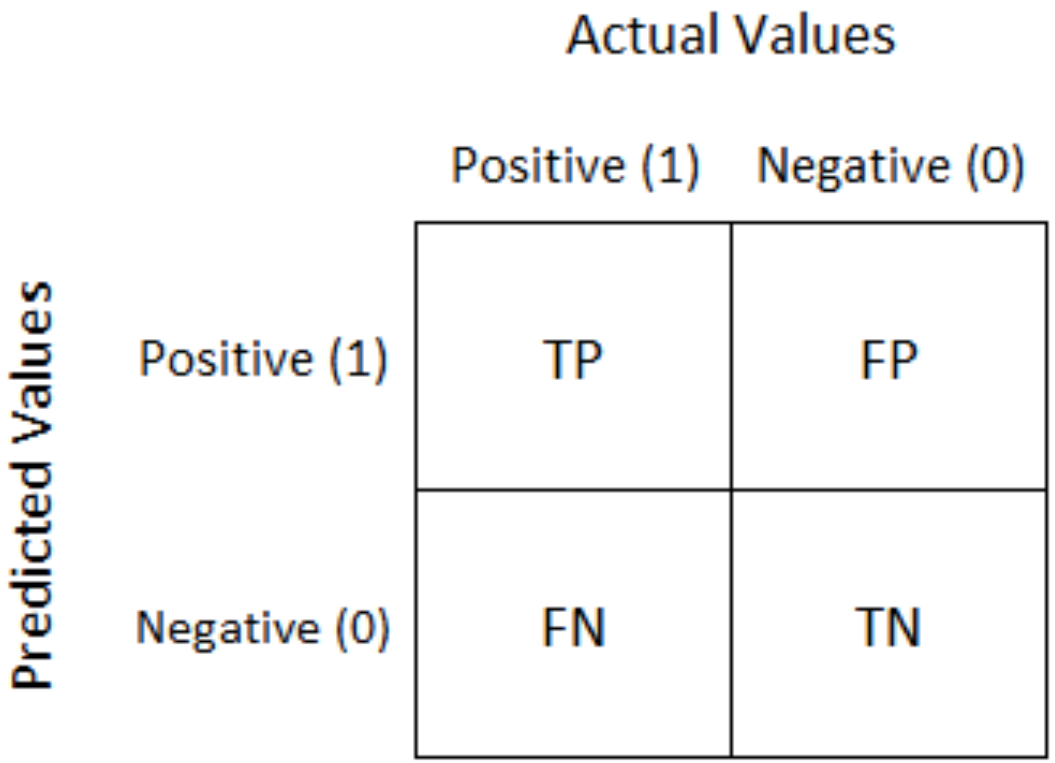
Evaluation des résultats de classification

- L'évaluation d'un modèle de classification se fait par différents metriques.
- **La matrice de confusion** est en quelque sorte un résumé des résultats de prédiction pour un problème de classification particulier. Elle compare les données réelles d'un échantillon à celles prédites par un modèle. Les prédictions justes et fausses sont révélées et réparties par classe, ce qui permet de les comparer avec des valeurs définies.
- Également connue sous le nom de tableau de contingence, la matrice de confusion permet d'évaluer les performances d'un modèle de classification. Elle montre donc à quel point un certain modèle peut être confus lorsqu'il fait des prédictions. Dans sa forme la plus simple, il s'agit d'une matrice 2X2. Pour des problèmes de classification plus complexes, il est toujours possible d'ajouter des lignes et des colonnes à la forme de base.

Evaluation des résultats de classification (Suite)

- La matrice de confusion permet de connaître d'une part les différentes erreurs commises par un algorithme de prédiction, mais plus important encore, de connaître les différents types d'erreurs commis. En les analysant, il est possible de déterminer les résultats qui indiquent comment ces erreurs ont eu lieu.
- La connaissance du type d'erreur est un avantage de taille de la matrice de confusion.
- Les résultats d'une matrice de confusion sont classés en quatre grandes catégories: les vrais positifs (TP), les vrais négatifs (TN), les faux positifs (FP) et les faux négatifs (FN).

Evaluation des résultats de classification (Suite)

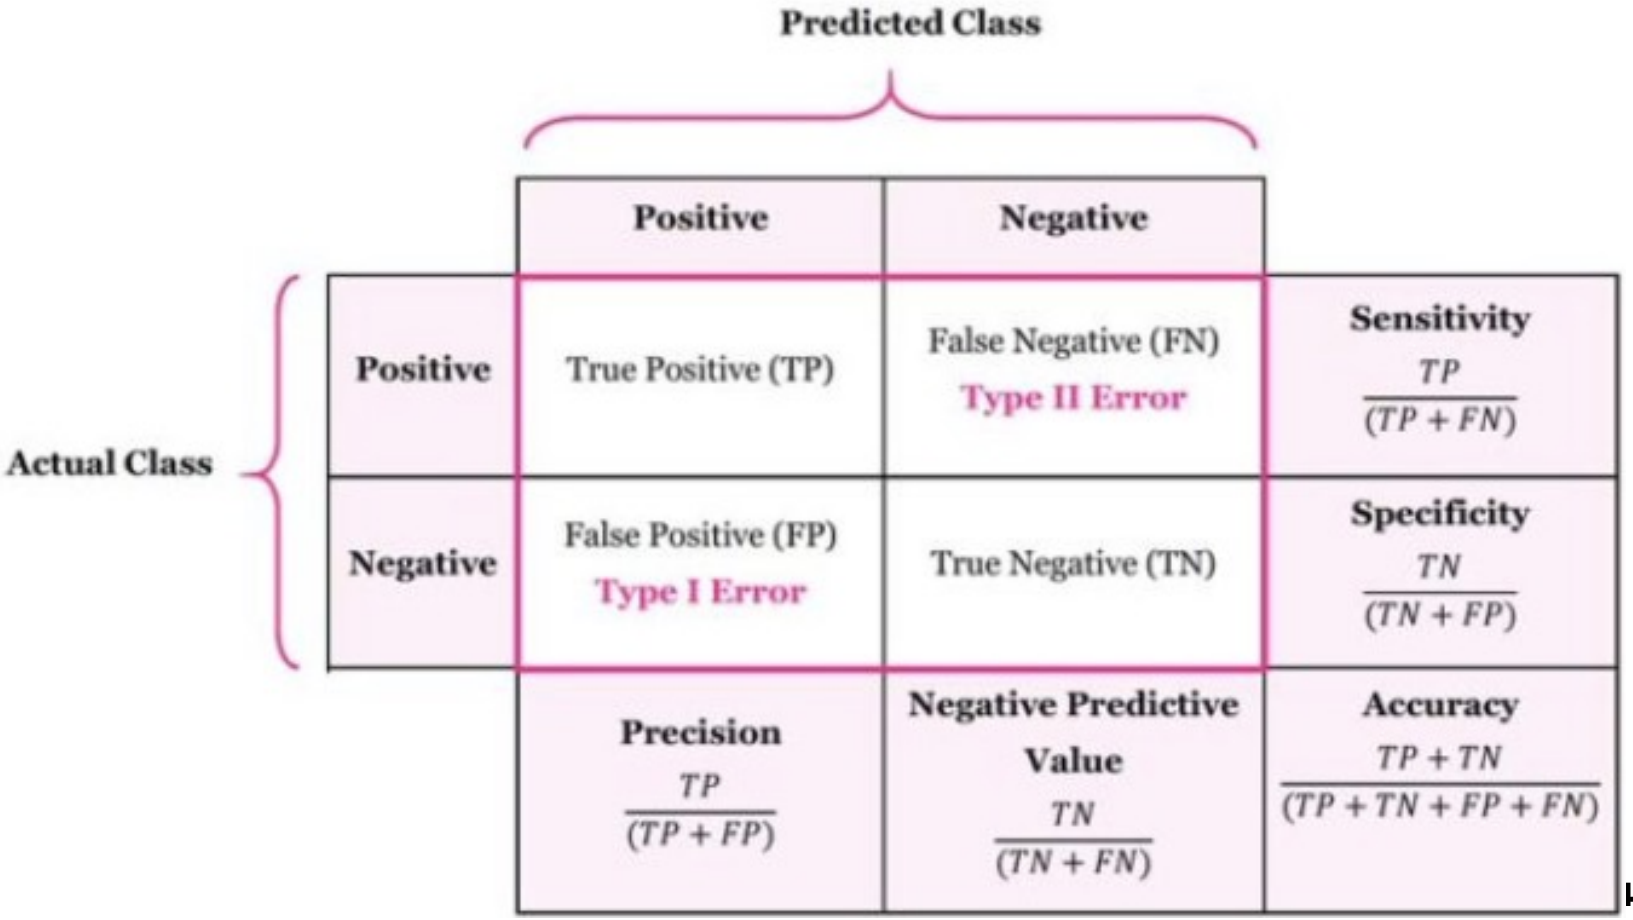


Evaluation des résultats de classification (Suite)

- **Les vrais positifs ou TP (11)** (true positive) indiquent les cas où les prédictions et les valeurs réelles sont effectivement positives. Dans l'exemple mentionné plus haut, cela signifie que le système reconnaît une personne normale et qui l'est réellement.
- **Les vrais négatifs ou TN (00)** (true negative) indiquent par contre les cas où les prédictions et les valeurs réelles sont toutes les deux négatives. Avec le même exemple, le test indique alors qu'une une personne n'est pas normale, ce qui est bel et bien le cas.
- **Les faux positifs ou FP (01)** (false positive) indiquent quant à eux une prédiction positive contraire à la valeur réelle qui est négative. En poursuivant avec l'exemple, cela implique les cas où des personnes de la classe insuffisant sont considérés comme normales.
- **Les faux négatifs ou FN (10)** font référence aux cas où les prédictions sont négatives alors que les valeurs réelles sont positives. Dans le cas de notre système, cela désigne des personnes normales ont été classés comme insuffisants.

Evaluation des résultats de classification (Suite)

- En plus de la matrice de confusion, il y'a aussi d'autres métriques:



Evaluation des résultats de classification (Suite)

- **La precision:** accuracy (ACC) est calculée comme le nombre de toutes les prédictions correctes divisé par le nombre total de l'ensemble de données.
- La meilleure précision est de 1.0, tandis que la pire est de 0.0.

$$\mathrm{ACC} = \frac{\mathrm{TP} + \mathrm{TN}}{\mathrm{TP} + \mathrm{TN} + \mathrm{FN} + \mathrm{FP}} = \frac{\mathrm{TP} + \mathrm{TN}}{\mathrm{P} + \mathrm{N}}$$

Evaluation des résultats de classification (Suite)

- **Sensibilité** (Rappel ou taux de vrais positifs) (SN) est calculée comme le nombre de prédictions positives correctes divisé par le nombre total de positifs.
- Il est aussi appelé rappel (REC) ou taux de vrais positifs (TPR).
- La meilleure sensibilité est de 1.0, tandis que la pire est de 0.0.

$$SN = \frac{TP}{TP + FN} = \frac{TP}{P}$$

Evaluation des résultats de classification (Suite)

- **Spécificité** (taux de vrais négatifs) (SP) est calculée comme le nombre de prédictions négatives correctes divisé par le nombre total de négatifs. Il est également appelé taux de vrais négatifs (TNR).
- La meilleure spécificité est de 1.0, alors que la pire est de 0.0.

$$\mathrm{SP} = \frac{\mathrm{TN}}{\mathrm{TN} + \mathrm{FP}} = \frac{\mathrm{TN}}{\mathrm{N}}$$

Evaluation des résultats de classification (Suite)

- **Précision** (valeur prédictive positive) (PREC) est calculée comme le nombre de prédictions positives correctes divisé par le nombre total de prédictions positives. Elle est aussi appelée valeur prédictive positive (VPP).
- La meilleure précision est de 1.0, tandis que la pire est de 0.0.

$$\mathrm{PREC} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}$$

Evaluation des résultats de classification (Suite)

- **Matthews correlation coefficient** (MCC) est un coefficient de corrélation calculé en utilisant les quatre valeurs dans la matrice de confusion.

$$\mathrm{MCC} = \frac{\mathrm{TP} \cdot \mathrm{TN} - \mathrm{FP} \cdot \mathrm{FN}}{\sqrt{(\mathrm{TP} + \mathrm{FP})(\mathrm{TP} + \mathrm{FN})(\mathrm{TN} + \mathrm{FP})(\mathrm{TN} + \mathrm{FN})}}$$

Evaluation des résultats de classification (Suite)

- Le **F-score** est une moyenne harmonique de précision et de rappel.

$$F_\beta = \frac{(1+\beta^2)(\mathrm{PREC}\cdot\mathrm{REC})}{(\beta^2\cdot\mathrm{PREC}+\mathrm{REC})}$$

- β peut être égale à 0.5, 1, or 2.

$$F_{0.5} = \frac{1.25\cdot\mathrm{PREC}\cdot\mathrm{REC}}{0.25\cdot\mathrm{PREC}+\mathrm{REC}}$$

$$F_1 = \frac{2\cdot\mathrm{PREC}\cdot\mathrm{REC}}{\mathrm{PREC}+\mathrm{REC}}$$

$$F_2 = \frac{5\cdot\mathrm{PREC}\cdot\mathrm{REC}}{4\cdot\mathrm{PREC}+\mathrm{REC}}$$

Evaluation des résultats de classification (Suite)

- La moyenne harmonique de n nombres est définie comme n divisé par la somme des inverses de chaque nombre.
- Autrement dit, pour calculer la moyenne harmonique, on additionne les nombres inverses de chacune des observations. Puis on divise le nombre total d'observations de notre série de valeurs par la somme obtenue.
- Voici donc la moyenne harmonique de 20 et 30 : $H = 2/ (1/20 + 1/30) = 24$

https://www.modalisa.com/logiciel/modalisa/support/lexique/moyenne-harmonique/

Evaluation des résultats de classification (Suite)

- Exemple:

		Predicted	
		Positive	Negative
Observed	Positive	6	4
	Negative	2	8

- Calculer les métriques précédents sur le tableau ci-dessus.

Evaluation des résultats de classification (Suite)

- Calcul des métriques:

measure		calculated value
Error rate	ERR	6 / 20 = 0.3
Accuracy	ACC	14 / 20 = 0.7
Sensitivity True positive rate Recall	SN TPR REC	6 / 10 = 0.6
Specificity True negative rate	SP TNR	8 / 10 = 0.8
Precision Positive predictive value	PREC PPV	6 / 8 =0.75
False positive rate	FPR	2 / 10 = 0.2